EDUCACIÓN
SECRETARÍA DE EDUCACIÓN PÚBLICA

TECNOLÓGICO NACIONAL DE MÉXICO

Tecnológico Nacional De México

Instituto Tecnológico De Tijuana

Subdirección Académica

Departamento de Sistemas y Computación

Semestre Enero - Junio 2022

Ingeniería Informática

Datos Masivos

Práctica 1 - Conceptos básicos de estadística

Unidad 2

Perez Ortega Victoria Valeria **No.18210718**

Israel López Pablo **No.17210585**

JOSE CHRISTIAN ROMERO HERNANDEZ

Tijuana, B.C. a 04 de Mayo de 2022.

Documentar y ejecutar el ejemplo de la documentación de spark de **Basic Statistics** , en su branch correspondiente.

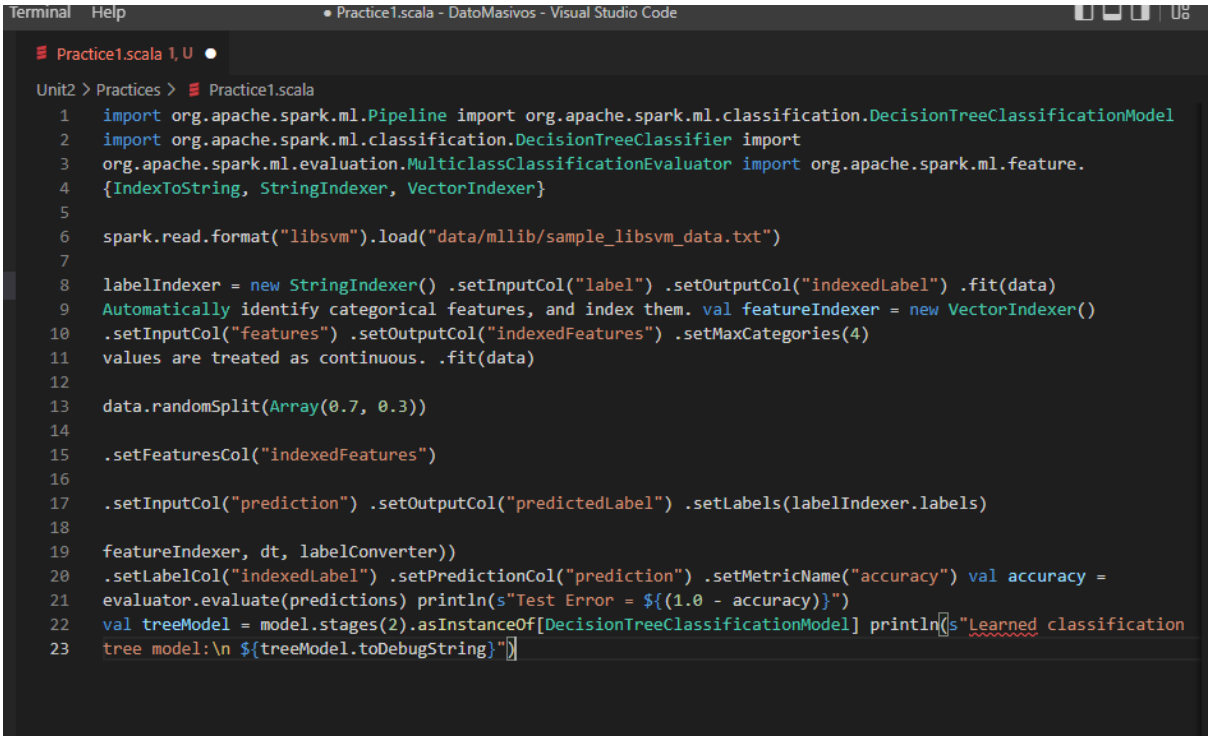

import org.apache.spark.ml.Pipeline import
org.apache.spark.ml.classification.DecisionTreeClassificationModel
import org.apache.spark.ml.classification.DecisionTreeClassifier import
org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator import
org.apache.spark.ml.feature.
{IndexToString, StringIndexer, VectorIndexer}

spark.read.format("libsvm").load("data/mllib/sample_libsvm_data.txt")

labelIndexer = new StringIndexer() .setInputCol("label") .setOutputCol("indexedLabel")
.fit(data)
Automatically identify categorical features, and index them. val featureIndexer = new
VectorIndexer()
.setInputCol("features") .setOutputCol("indexedFeatures") .setMaxCategories(4)
values are treated as continuous. .fit(data)

data.randomSplit(Array(0.7, 0.3))

.setFeaturesCol("indexedFeatures")

```
.setInputCol("prediction") .setOutputCol("predictedLabel") .setLabels(labelIndexer.labels)

featureIndexer, dt, labelConverter))
.setLabelCol("indexedLabel") .setPredictionCol("prediction") .setMetricName("accuracy") val
accuracy =
evaluator.evaluate(predictions) println(s"Test Error = ${(1.0 - accuracy)}")
val treeModel = model.stages(2).asInstanceOf[DecisionTreeClassificationModel]
println(s"Learned classification
tree model:\n ${treeModel.toDebugString}")
```