Tecnológico Nacional De México

Instituto Tecnológico De Tijuana

Subdirección Académica

Departamento de Sistemas y Computación

Semestre Enero - Junio 2022

Ingeniería Informática

Datos Masivos

Práctica 2 - Decision Tree Classifier

Unidad 2

Perez Ortega Victoria Valeria **No.18210718**

Israel López Pablo **No.17210585**

JOSE CHRISTIAN ROMERO HERNANDEZ

Tijuana, B.C. a 04 de Mayo de 2022.

Documentar y ejecutar el ejemplo de la documentación de spark del **Decision tree classifier**, en su branch correspondiente.

https://spark.apache.org/docs/latest/mllib-decision-tree.html

Practica 2

En el primer paso, necesitamos importar la biblioteca necesaria para ejecutar el código.

```
import org.apache.spark.ml.Pipeline
import org.apache.spark.ml.classification.DecisionTreeClassificationModel
import org.apache.spark.ml.classification.DecisionTreeClassifier
import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator
import org.apache.spark.ml.feature.{IndexToString, StringIndexer,
VectorIndexer}
```

En este paso es necesario cargar los datos para este paso es necesario tomar el archivo "sample_libsvm_data.txt"

```
val data =
spark.read.format("libsvm").load("C:/Spark/data/mllib/sample_libsvm_data.txt"
)
```

Result

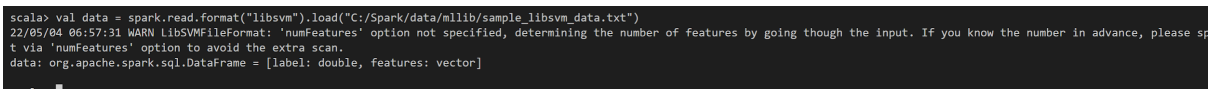

necesitamos crear labelindexer y featureIndexer, esto es necesario para agregar metadatos y ajustar el conjunto de datos

```
val labelIndexer = new StringIndexer()
  labelIndexer.setInputCol("label")
  labelIndexer.setOutputCol("indexedLabel")
  labelIndexer.fit(data)

val featureIndexer = new VectorIndexer()
```

```
featureIndexer.setInputCol("features")
featureIndexer.setOutputCol("indexedFeatures")
featureIndexer.setMaxCategories(4)
 featureIndexer.fit(data)
```

Result

```
scala> val labelIndexer = new StringIndexer()
labelIndexer: org.apache.spark.ml.feature.StringIndexer = strIdx_80cf65a830f7

scala>  labelIndexer.setInputCol("label")
res0: labelIndexer.type = strIdx_80cf65a830f7

scala>   labelIndexer.setOutputCol("indexedLabel")
res1: labelIndexer.type = strIdx_80cf65a830f7

scala>   labelIndexer.fit(data)
res2: org.apache.spark.ml.feature.StringIndexerModel = strIdx_80cf65a830f7
```

```
scala> val featureIndexer = new VectorIndexer()
featureIndexer: org.apache.spark.ml.feature.VectorIndexer = vecIdx_590ef98909b4

scala>   featureIndexer.setInputCol("features")
res3: featureIndexer.type = vecIdx_590ef98909b4

scala>   featureIndexer.setOutputCol("indexedFeatures")
res4: featureIndexer.type = vecIdx_590ef98909b4

scala>   featureIndexer.setMaxCategories(4)
res5: featureIndexer.type = vecIdx_590ef98909b4

scala>   featureIndexer.fit(data)
res6: org.apache.spark.ml.feature.VectorIndexerModel = vecIdx_590ef98909b4
```

Agregue el siguiente código para separar los datos para probar y entrenar

```
val Array(trainingData, testData) = data.randomSplit(Array(0.7, 0.3))
```

```
scala> val Array(trainingData, testData) = data.randomSplit(Array(0.7, 0.3))
trainingData: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [label: double, features: vector]
testData: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [label: double, features: vector]
```

en esta sección hacemos todas las características necesarias para el modelo de tren

```
val dt = new DecisionTreeClassifier()
  dt.setLabelCol("indexedLabel")
  dt.setFeaturesCol("indexedFeatures")
```

Result

```
scala> val dt = new DecisionTreeClassifier()
dt: org.apache.spark.ml.classification.DecisionTreeClassifier = dtc_b2ca56542c3a

scala>   dt.setLabelCol("indexedLabel")
res7: org.apache.spark.ml.classification.DecisionTreeClassifier = dtc_b2ca56542c3a

scala>   dt.setFeaturesCol("indexedFeatures")
res8: org.apache.spark.ml.classification.DecisionTreeClassifier = dtc_b2ca56542c3a
```

ahora volvemos a convertir etiquetas indexadas a originales

```
val labelConverter = new IndexToString()
  labelConverter.setInputCol("prediction")
  labelConverter.setOutputCol("predictedLabel")
  labelConverter.setLabels(labelIndexer.labels)
```

Result

```
scala> val labelConverter = new IndexToString()
labelConverter: org.apache.spark.ml.feature.IndexToString = idxToStr_0ae00975e290

scala>   labelConverter.setInputCol("prediction")
res9: labelConverter.type = idxToStr_0ae00975e290

scala>   labelConverter.setOutputCol("predictedLabel")
res10: labelConverter.type = idxToStr_0ae00975e290

scala>   labelConverter.setLabels(labelIndexer.labels)
<console>:33: error: value labels is not a member of org.apache.spark.ml.feature.StringIndexer
        labelConverter.setLabels(labelIndexer.labels)
                                              ^
```

ahora cambiamos los indexadores y el árbol a la canalización

```
val pipeline = new Pipeline()
  pipeline.setStages(Array(labelIndexer, featureIndexer, dt, labelConverter))
```

Result

Ahora es necesario entrenar al modelo.

```
val model = pipeline.fit(trainingData)
```

Result

Nosotros hacemos predicciones(masculino)

Buscar esto en

```
val predictions = model.transform(testData)
```

Result

En esta sección mostramos 5 filas

```
predictions.select("predictedLabel", "label", "features").show(5)
```

Result

este último código es seleccionar un error de prueba de cálculo

```
val evaluator = new MulticlassClassificationEvaluator()
  .setLabelCol("indexedLabel")
  .setPredictionCol("prediction")
  .setMetricName("accuracy")
val accuracy = evaluator.evaluate(predictions)
println(s"Test Error = ${(1.0 - accuracy)}")

val treeModel = model.stages(2).asInstanceOf[DecisionTreeClassificationModel]
println(s"Learned classification tree model:\n ${treeModel.toDebugString}")
```